

Análisis de biblioteca FALKO Lib en detección de cierre de ciclos con LIDAR 2D

Martin Nievas¹, Sebastián Bedín²

Resumen—La detección de cierre de ciclos es un tema de interés en la robótica y en particular en los métodos de navegación basados en SLAM (*Simultaneous Localization And Mapping*), dado que permite realizar correcciones sobre la estimación de la pose del robot de forma precisa. En este trabajo presentamos un análisis de la biblioteca FALKOLib (*Fast Adaptive Laser Keypoint Orientation-invariant*) para su aplicación en la detección del cierre de ciclos. El interés de aplicar esta herramienta por sobre otras soluciones como ICP (*Iterative Closest Point*), radica en su menor costo computacional. Se presentan los resultados obtenidos sobre simulaciones realizadas con un LIDAR2D, analizando diferentes parámetros para la detección de cierres de ciclos.

Index Terms—Loop closure, Localization, LIDAR 2D

I. INTRODUCCIÓN

La problemática del cierre de ciclos utilizando extractores y descriptores de *keypoints* para escaneos 2D está ampliamente desarrollado en la literatura. Podemos ver en la Fig. 1 un ejemplo de arquitectura utilizado para el cierre de ciclo en [1]. Podemos decir que la conclusión general a la que llegan diversos trabajos es que: realizar la detección de cierre de ciclos utilizando únicamente descriptores de escaneos 2D no es una solución robusta. Por este motivo se suele aplicar un método más robusto para verificar la asociación entre nubes de puntos. Usualmente se utiliza ICP.

Esta solución híbrida ofrece dos beneficios:

- Al describir las nubes de puntos utilizando *features* 2D, la búsqueda de asociaciones en un mapa grande se puede realizar de forma muy rápida. En este punto es común el uso de alguna estructura de datos que agilice el proceso de búsqueda. BoW (*bag-of-words*) es una solución ampliamente utilizada.
- Al utilizar ICP se puede asegurar con un buen grado de confianza si las nubes de puntos candidatas poseen una transformación que las relaciona o no.

Por último vale la pena aclarar que el algoritmo de ICP es muy sensible a la transformación inicial para su minimización. Pudiendo, en algunas situaciones, descartar asociaciones válidas. En estos casos se suele utilizar procesos de comparación geométrica de los *keypoints* extraídos. Por ejemplo, se podría utilizar RANSAC (*Random sample consensus*) para a determinación de una transformación inicial de ICP más robusta.

¹Centro de Investigación en Informática para la Ingeniería – CIII. Universidad Tecnológica Nacional, Facultad Regional Córdoba martin.nievas.ar@gmail.com

²Instituto de Ciencias de la Computación (ICC-CONICET) Universidad de Buenos Aires, Buenos Aires, Argentina sebadedin@gmail.com



Figura 1. Arquitectura utilizada para el cierre de ciclos con descriptores para LIDAR 2D. Observamos que la etapa final del proceso consiste en este caso de una asociación mediante ICP.

II. ALCANCES DEL TRABAJO

En este trabajo se aborda la problemática de la detección, descripción y asociación de la información de un sensor LIDAR 2D. Específicamente la implementación de la biblioteca FALKOLib presentada en [2] para cumplir con estas tareas. La biblioteca en cuestión cuenta con dos extractores de *keypoints*: FALKO y OC (*Orthogonal Corner Detector*) y dos tipos de descriptores BSC (*Binary Shape Context*) y CGH (*Computing Corner Orientation*). En este trabajo enfocamos el análisis del par FALKO-BSC dado que es presentado como la combinación que posee mejor rendimiento en detección.

III. FALKO LIB

Las mediciones de un LIDAR 2D son un conjunto de puntos que aproximan la geometría del ambiente. En mediciones con sensores de poca resolución angular, a una gran distancia, ésta aproximación es menos precisa.

Los ambientes creados por humanos generalmente están compuestos por paredes ortogonales, por lo que una gran cantidad de mediciones LIDAR corresponderá a puntos alineados a lo largo de dos direcciones dominantes. Esta condición es utilizada para encontrar puntos claves, conocidos como esquinas, principalmente entre dos paredes.

III-A. Detección de keypoints

El primer paso es la detección de puntos de interés en las mediciones láser. El detector FALKO está diseñado para ser invariante a rotaciones, e independiente de la densidad de puntos obtenidas por el sensor LIDAR.

Para cada punto en la medición laser se calcula el conjunto $C(p_i)$ dado por:

$$C(p_i) = p_j \in S : ||p_j - p_i|| < r_i$$

Donde r_i se elige para que la vecindad de cada punto p_i tenga un número uniforme de vecinos, conforme aumenta la distancia desde el sensor $||p_i||$. El valor r_i se elige como $r_i = \alpha \exp(\beta ||p_i||)$, donde $\alpha = 0,2$ y $\beta = 0,07$. En la Fig. 2 podemos observar como se comporta el valor de r_i

para diferentes valores α y β . A medida que aumenta el valor $\|p_i\|$, el punto está más lejos del sensor, se tienen en cuenta un radio más grande para determinar los vecinos cercanos.

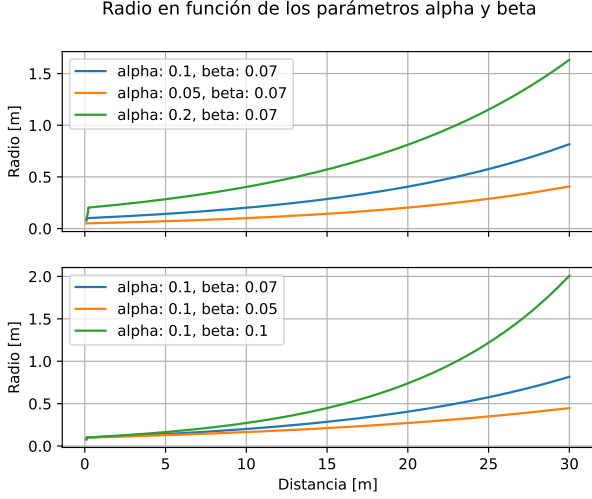


Figura 2. Comportamiento del valor r_i en función de los parámetros α y β . Para un α fijo, incrementos en β permiten incrementar exponencialmente el radio de búsqueda de vecinos más cercanos. Para incrementos en α , podemos incrementar el radio de búsqueda para distancias más cercanas al laser manteniendo un radio proporcional para pequeños cambios de distancia.

El conjunto $C(p_i)$ es luego dividido en dos subconjuntos:

$$C_L(i) = \{p_j \in C(p_i) : j < i\}$$

$$C_R(i) = \{p_j \in C(p_i) : j > i\}$$

Los puntos que no cumplen con la condición $|C_L| < 2$ y $|C_R| < 2$ son descartados de los posibles candidatos a esquinas. Los puntos extremos x_L y x_R de cada punto cercano del punto candidato son definidos como:

$$\begin{aligned} x_L &= p_{j_{min}} : j_{min} = \operatorname{argmin}\{p_j \in C_L(p_i)\} \\ x_R &= p_{j_{max}} : j_{max} = \operatorname{argmin}\{p_j \in C_L(p_i)\} \end{aligned} \quad (1)$$

El triángulo $\triangle p_i x_L x_R$ es evaluado geoméricamente para realizar una aproximación de la esquina como se puede observar en la Fig. 6.

Dado el segmento $\|\overline{x_L x_R}\|$ como la magnitud de la base del triángulo, si es menor que $\frac{r_i}{\beta}$ el punto es descartado. El parámetro β es elegido para tener en cuenta las limitaciones específicas de apertura de la esquina. Con este valor pueden descartarse candidatos a esquinas en base a las propiedades geométricas de los puntos vecinos. Grandes valores de β permiten al mismo tiempo considerar esquinas más abiertas y cerradas como se puede observar en la Fig. 3 Por otro lado, en la Fig.

Luego, por cada punto candidato a esquina se calcula un puntaje que la clasifica como tal. Para esto se genera un grilla polar que divide el espacio en sectores circulares centrado en el punto candidato p_i como se puede apreciar en la Fig. 6




Figura 3. Efecto sobre la detección de esquinas para diferentes valores de β . En verde las esquinas detectadas y consideradas como candidato a punto característico. En rojo las esquinas descartadas.




Figura 4. Efecto de la apertura angular sobre la detección de esquinas para un β fijo y diferentes valores de α . En verde las esquinas detectadas y en rojo las descartadas. A medida que α aumenta, se limita la dispersión de apertura del ángulo de la esquina

Para cada punto $p_{j,L} \in C_L(p_i)$ y $p_{j,R} \in C_R(p_i)$ se calcula una orientación cuantificada para el punto p_i , teniendo en cuenta la cantidad de sectores circulares s_n como:

$$\phi_{j,L} = \left\lfloor \frac{s_n}{2\pi} \tan^{-1} \left(\frac{p_{j,y} - p_{i,y}}{p_{j,x} - p_{i,x}} \right) \right\rfloor, \forall p_j \in C_L(p_i) \quad (2)$$

$$\phi_{j,R} = \left\lfloor \frac{s_n}{2\pi} \tan^{-1} \left(\frac{p_{j,y} - p_{i,y}}{p_{j,x} - p_{i,x}} \right) \right\rfloor, \forall p_j \in C_R(p_i) \quad (3)$$

Se establece una función de distancia $d_\theta(\phi_1, \phi_2)$ entre las orientaciones cuantificadas como:

$$d_\theta(\phi_1, \phi_2) = \left((\phi_1 - \phi_2) + \frac{s_n}{2} \right) \pmod{s_n} - \frac{s_n}{2}. \quad (4)$$

Mediante esta función, podemos determinar la alineación de los conjuntos C_L , C_R de forma que sea invariante a las




Figura 5. Sectores circulares para un $s_n = 16$. En rojo el punto candidato a esquina p_j y un punto vecino p_i utilizado para calcular $\phi_{j,R}$. En celeste la aproximación del triángulo calculado para la esquina

rotaciones:

$$score_L(p_i) = \sum_{h=i-1}^{j_{min}} \sum_{k=h-1}^{j_{min}} |d_\theta(\phi_h, \phi_k)|, \quad (5)$$

$$score_R(p_i) = \sum_{h=i+1}^{j_{min}} \sum_{k=h+1}^{j_{min}} |d_\theta(\phi_h, \phi_k)|, \quad (6)$$

Para cada conjunto, entre más puntos estén alineados en la misma dirección, menor puntaje total se obtendrá. En la Fig. 6 se puede observar el puntaje obtenido para dos esquinas.

Los puntos de interés son elegidos como mínimos locales (o máximos locales con inversión de valor) en la función de puntaje:

$$score(p_i) = score_L(p_i) + score_R(p_i)$$

utilizando una supresión de no mínimos (NMS) en base a un rango predeterminado $nms_r = 0,20m$




Figura 6. Ejemplo de un punto de interés extraído mediante FALKO. En azul los puntajes obtenidos, en verde los puntos candidatos, en celeste la aproximación del triángulo compuesto por los mismos y en rojo la orientación calculada. Notar como el p_i de la esquina obtiene el menor puntaje del conjunto local analizado

III-B. Parámetros del detector

El entorno utilizado para la descripción está definido por dos parámetros r_n y α_n . El primero determina el número de discos radiales centrados en el punto de interés p_i , mientras que el segundo determina la cantidad de sectores circulares en los cuales se divide la vecindad de punto. Para determinar los puntos a considerar por el detector, se utiliza un radio r_d calculado como $r_d = \alpha \exp(\beta ||k_i||)$, donde α y β modifican el entorno de detección, y k_i es el punto de interés detectado como esquina.

III-B1. Radio: El radio r_d determina el vecindario alrededor del keypoints k_i . Es función de la distancia mediante una función exponencial de dos parámetros α y β . La elección de estos parámetros es importante, ya que determina el vecindario en la detección de la esquina. En la parte superior de la Fig. 2 podemos observar como se comporta el valor de r_i para diferentes valores α .

III-B2. beta: El parámetro β permite evaluar la apertura angular de la esquina. En combinación con r_i , este parámetro permite limitar el vecindario que se analiza para cada medición del laser.

Como podemos observar en la parte inferior de la Fig. 2, a medida que incrementa el valor de β se incrementa el entorno a considerar para el detector. Esto es útil, ya que a medida que aumenta el valor $||p_i||$, el punto está más lejos del sensor, y se debe tener en cuenta un radio más grande para determinar los vecinos cercanos debido a la dispersión propia del LIDAR 2D.

IV. DESCRIPTORES

Una vez determinado el punto de interés, se realiza una descripción del entorno utilizando un descriptor. Una estrategia es ubicar los puntos en un histograma centrado en el punto de interés, analizando los puntos vecinos en una región determinada. Un inconveniente con esta técnica es la dependencia con la densidad de puntos, ya que la misma forma detectada desde dos puntos de vista diferentes puede dar como resultado dos distribuciones de histograma diferentes.

IV-A. Descriptor BSC

El descriptor BSC (Binary Shape Context Shape) es un descriptor local que representa la distribución de puntos en un histograma lineal-polar. Los contenedores del histograma centrados en el keypoint cuentan los puntos vecinos que están dentro de la región correspondiente al contenedor. La principal desventaja de este enfoque es su dependencia de la densidad de puntos. De hecho, debido a la cuantización angular del escáner láser, la misma forma detectada desde dos puntos de vista diferentes puede resultar en dos distribuciones de histograma diferentes.

Para cada punto de interés el d_{BSC} es definido como:

$$BSC_{mj} = \begin{cases} 1 & \text{if } \exists p_i : (p_i - k_p) \in \overline{BSC_{mj}} \\ 0 & \end{cases} \quad (7)$$

Esto genera descriptores binarios que luego pueden compararse utilizando la función de distancia Hamming:

$$d_{BSC}(BSC_1, BSC_2) = \sum_{m=1}^{r_n} \sum_{j=1}^{\alpha_n} BSC_{1,mj} \oplus BSC_{2,mj} \quad (8)$$

El descriptor ofrece dos parámetros para especificar la sensibilidad a la densidad de puntos, siendo el número de cuantizaciones radiales α_n y el número de cuantizaciones angulares r_n . En la Fig.7 podemos observar la segmentación generada alrededor del punto de interés p_i .




Figura 7. Segmentación utilizada por el descriptor BSC con $r_n = 4$ y $\alpha_n = 16$. En azul los puntos obtenidos del laser 2D, en verde las celdas activas utilizadas por el descriptor y en la flecha violeta la orientación calculada de la esquina.

IV-B. Asociación de keypoints

La biblioteca cuenta con un módulo de asociaciones de *keypoints*, *matcher*, configurable a la combinación de detectores y descriptores presentes en la misma. Este módulo ofrece dos parámetros de configuración: umbral de distancia y umbral de distancia del descriptor. Debido a la alta sensibilidad a la rotación del descriptor BSC, es recomendable utilizar umbrales de distancia bajos. El umbral del descriptor hace referencia al distancia Hamming máxima permitida.

V. EXPERIMENTOS

Para los experimentos se utilizó el simulador Gazebo Fortress con un robot de tracción diferencial y un LIDAR 2D montado en su parte superior. Se realizaron cuatro tipos de caminos utilizando un LIDAR 2D de 360 puntos con un alcance máximo de 10m, un amplitud angular de 360° y un error de medición de 2,5cm. Para el cálculo de los resultados se utilizó la pose global del robot. Esta información se obtuvo del algoritmo de slam provisto por el paquete de ROS 2 *slam_toolbox*. Los experimentos realizados buscan representar distintas situaciones de interés para evaluar de forma cualitativa el uso de la biblioteca para la detección de cierre de ciclos. Podemos listar algunas de las características de cada recorrido:

- Experimento 1: es un recorrido de tres vueltas alrededor de un entorno que presenta una alta simetría en sus cuatro esquinas. El desafío en este experimento es poder filtrar los falsos positivos en las asociaciones.
- Experimento 2 y 3: son caminos largos que presentan cierre de ciclos en varias situaciones incluso repasando por el mismo lugar en dirección contraria. El entorno ofrece muchos detalles evitando la simetría.

Tabla I
ETAPA UTILIZADOS EN EXPERIMENTOS

Proceso	Parámetro	Valor
FALKO	Min Extraction Range	0.5 m
FALKO	Max Extraction Range	10.0 m
FALKO	Subbeam	True
FALKO	Neigh A	0.3
FALKO	Neigh B	0.1
FALKO	Neigh Min Point	2 points
FALKO	B Ratio	2.5
FALKO	Grid Sectors	16
FALKO	NMS Radius	0.3 m
BSC	Circular Sector Number	16
BSC	Radial Ring Number	8
Matcher	Distance Threshold	0.5 m
Matcher	Descriptor Threshold	15

- Experimento 4: Es un camino corto donde el robot revisita los lugares pasando en distintas direcciones. Además el entorno presenta cierta simetría.

En todos los experimentos la biblioteca fue utilizada con los parámetros descriptos en la Tabla I. Además se determinó un criterio umbral de mínima cantidad de *keypoints* entre asociaciones de nubes de puntos para determinar el par de nubes candidatas para la detección del cierre de ciclo. Se utilizaron cuatro umbrales por cada experimento.

En la figura Fig. 8 se puede ver el perfil de los caminos de cada experimento en línea roja punteada y en azul la asociación entre los distintos escaneos. Los puntos origen y fin de la línea azul representan la posición del robot al momento de obtener la nube de puntos. En la figura además se muestran cuatro diferentes situaciones de detección para cada experimento. Comenzando con un umbral de mínimo dos *keypoints* para asociar nubes de puntos hasta mínimo 5 *keypoints*.

Por último a cada asociación de par de nubes se le aplicó un filtro para descartar asociaciones de nubes de puntos consecutivas. Este filtro consiste en analizar la separación temporal entre escaneos, donde se tomaron como válidas aquellas que superan un umbral fijo. De esta forma nos aseguramos que en los resultados de estos experimentos sólo se analizan las asociaciones generadas por la revisita del robot al lugar.

VI. RESULTADOS

De la Fig. 8 se puede ver que al aumentar el umbral de *keypoints* se reduce significativamente la cantidad de falsos positivos. Esto reduce la cantidad de posibles candidatos a evaluar. Si vemos los datos presentados en la Tabla II, podemos ver que la cantidad de nodos con asociaciones se reduce considerablemente. Si analizamos la cantidad de asociaciones por cada nodo presentado en la Tabla III podemos ver que a partir de 3 *keypoints* por asociación cada nodo tiene en promedio entre 4 y 2 nodos candidatos. Esto reduce la cantidad de aplicaciones de ICP necesarias para la determinación del cierre de ciclo.

A partir de las asociaciones obtenidas en cada situación confeccionamos la Fig. 9. En ella representamos con un punto

Tabla II
CANTIDAD DE NODOS CON ASOCIACIONES

Umbral	Exp. 1	Exp. 2	Exp. 3	Exp. 4
1	760	1189	1166	1462
2	320	544	238	554
3	133	157	55	233
4	62	102	22	70
5	28	65	14	13

Tabla III
PROMEDIO DE ASOCIACIONES POR DE NODO

Umbral	Exp. 1	Exp. 2	Exp. 3	Exp. 4
1	16	32	15	25
2	3	4	2	7
3	2	3	1	5
4	2	3	1	3
5	2	2	1	2

la distancia y rotación relativa entre los nodos asociados. Teniendo en cuenta que el alcance máximo del LIDAR simulado es de 10m, se aprecia que para el umbral de 2 keypoints todos los nodos con distancia mayor a 10m son falsos positivos. En el caso del experimento 4, dada la topología del entorno ningún nodo se distancia más de 10m, solo por eso no presenta este desvío fuertemente marcado en el resto de los experimentos. El efecto de los falsos positivos se puede apreciar en la Fig. 8, donde se visualizan líneas de asociación para nodos distantes, en muchas ocasiones en lugares opuestos del mapa.

Al aumentar el valor umbral utilizado podemos ver que la distancia y la rotación comienzan a reducirse. Este efecto valida la fuerte dependencia del descriptor a la orientación. La orientación del *keypoint* puede variar porque el robot está rotado respecto de la posición original o porque está desplazado. El desplazamiento se puede traducir como una rotación dado que modifica el ángulo de visión del escaneo. En este sentido las nubes de puntos que comparten más *keypoints* son las que presentan una rotación y desplazamiento pequeños.

La apertura angular que se aprecia en la figura para el umbral más exigente está relacionada a la cantidad de secciones angulares del descriptor. cuanto menor número de secciones mayor apertura.

Para reforzar esta última idea, y aunque se desprende de los resultados, agregamos que la biblioteca no puede relacionar nubes de puntos del mismo lugar cuando el robot pasa exactamente por el mismo camino pero en sentido inverso.

VII. CONCLUSIONES

En este trabajo realizamos un análisis cualitativo sobre la biblioteca FALKOLib para su aplicación en métodos para la detección de cierre de ciclos. La biblioteca ofrece una gran cantidad de parámetros para su configuración. Esto favorece su configuración para una gran variedad de sensores y ambientes pero también aumenta la dificultad para su correcta implementación. Otro factor desfavorable de la biblioteca es la poca información que exporta al usuario final. Esta información sería muy útil para su correcta configuración.

En cuanto a su performance, si bien el detector de keypoints FALKO presenta una gran versatilidad el descriptor BSC es muy sensible a la orientación lo que reduce los campos de aplicación de esta biblioteca.

Por otro lado, la motivación original de este trabajo era la detección de cierre de ciclos en ambientes industriales; fábricas o almacenes en donde los robots deben seguir por un camino determinado para ir de un lugar a otro. En estas situaciones la diversidad de caminos está muy acotada y sería un ambiente propicio para el uso de este descriptor.

Por último, la etapa de la biblioteca encargada de las asociaciones de puntos presenta una lógica muy sencilla que podría mejorarse con técnicas de PnP (Perspective N-Points) o incluso RANSAC. Esto mejoraría la calidad de las asociaciones pero definiría un mínimo de 3 keypoints para poder relacionar distintas nubes de puntos.

VIII. REFERENCIAS

REFERENCIAS

- [1] S. Pujol, "Loop closure using laser 2d," 2021.
- [2] D. L. R. Fabjan Kallasi and S. Caselli, "Fast keypoint features from laser scanner for robot localization and mapping,," *IEEE Robotics & automation letters*, vol. 1, no. 1, 2016.

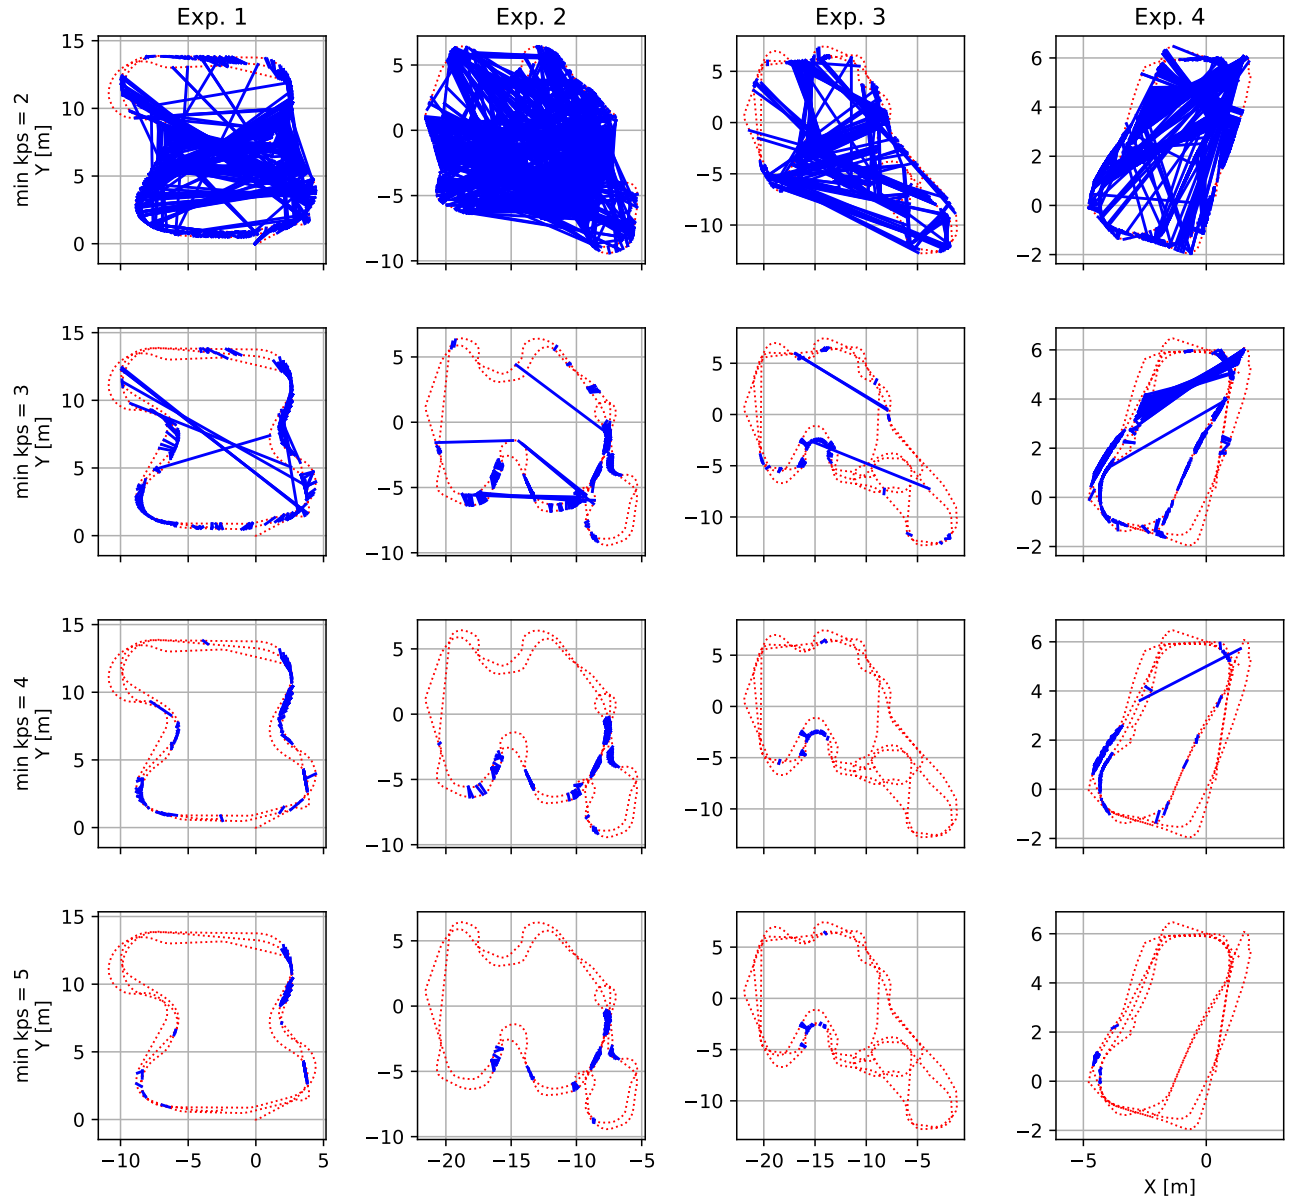


Figura 8. Recorrido de cuatro experimentos realizados para probar el funcionamiento de la biblioteca. En rojo se muestra el camino del robot. en azul se muestra las asociaciones de entre posiciones del robot que se pueden establecer aplicando un criterio de mínima cantidad de *keypoints* asociados. Se verifica que a mayor umbral de *keypoints* se reduce la cantidad de falsos positivos.

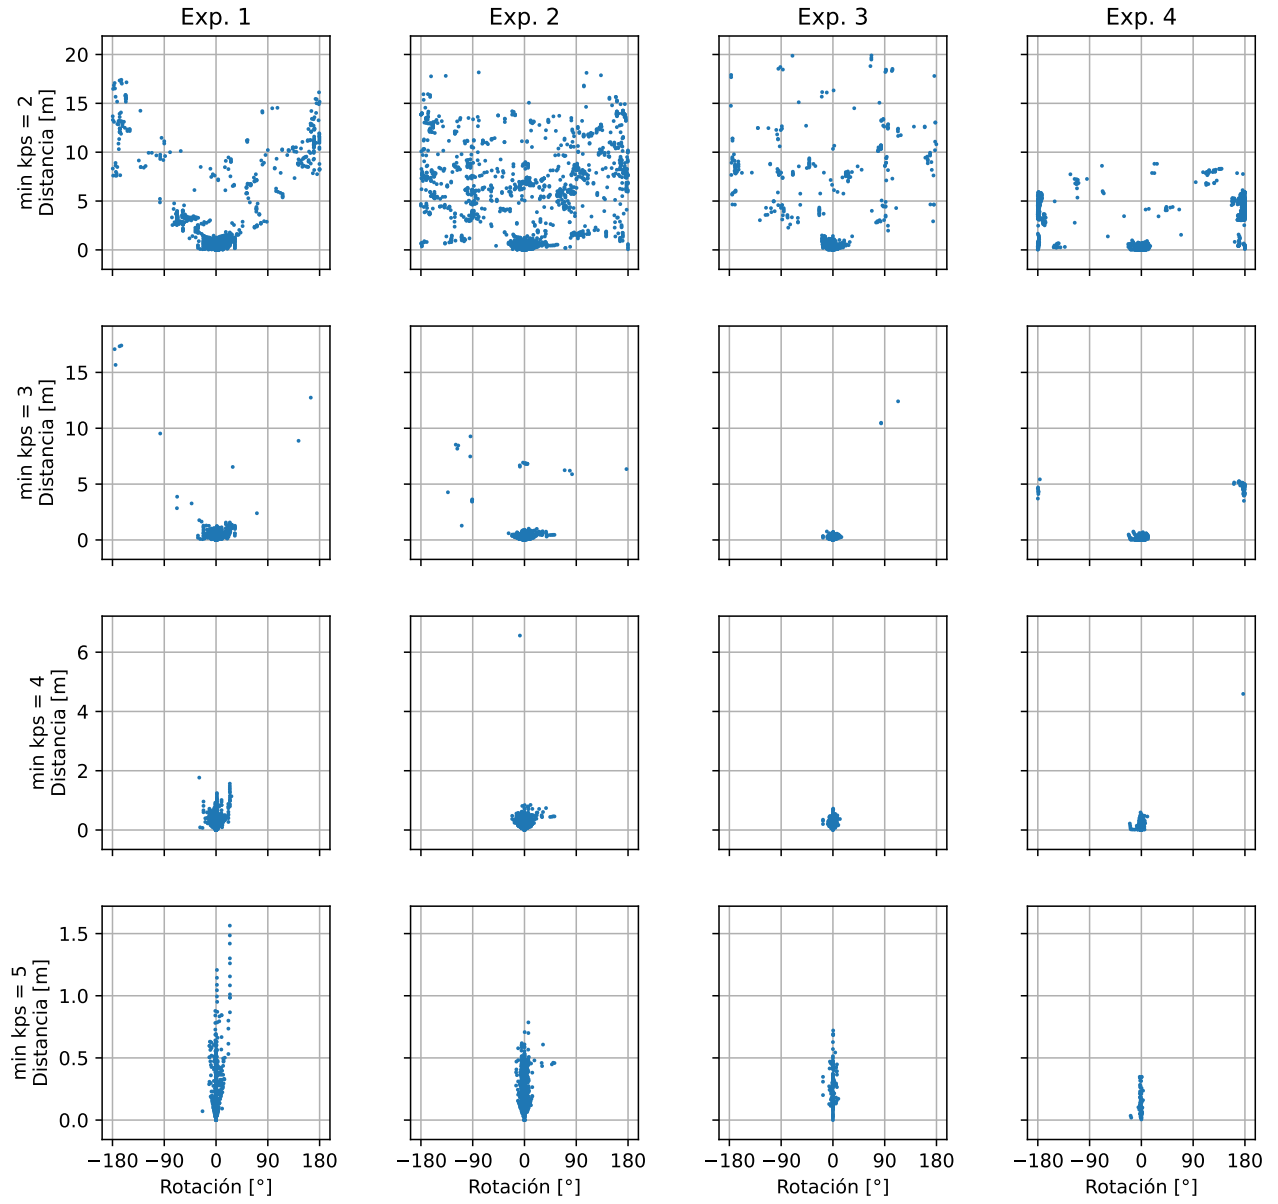


Figura 9. En la figura se representa por cada punto la distancia y rotación relativa entre nodos asociados para cada experimento y para cada nivel de umbral utilizado para detectar asociaciones. Se puede apreciar la reducción de puntos lejanos y no alineados a medida que se aplica un umbral más alto. En el caso del umbral $k_p=5$ se puede visualizar la dependencia en orientación del descriptor.